



中山大學
SUN YAT-SEN UNIVERSITY

计算机视觉期末报告

姓名 党政扬

学号

学院 智能工程学院

专业 智能科学与技术

2026 年 1 月 20 日

目录

1 引言：从实际需求出发的思考	1
1.1 计算机视觉的范式转移	1
1.2 从堆砌到精简：效率的呼唤	1
2 3D 场景表征：技术脉络与性能对比	1
2.1 显式几何表征：高效但语义匮乏	1
2.2 神经隐式表征：从 NeRF 到 3DGS 的革命	2
2.3 基础模型驱动的语义注入	3
3 HOV-SG 的复现、分析与反思	3
3.1 HOV-SG 的核心算法流程	3
3.2 复现中的性能瓶颈与问题分析	3
3.3 对“必要性”的质疑：来自实验的反思	5
4 空中抓取中的场景图应用	5
5 从感知到生成：具身智能的未来展望	6
5.1 生成式模型的双重角色	6
5.2 统一的感知-生成框架	6
5.3 轻量化与端侧部署的必要性	6
6 结论：技术与应用的双向驱动	6

从感知到交互：开放词汇 3D 场景图的表征演进与计算效率优化研究

党政扬

中山大学智能工程学院，广东 深圳 518107

摘要：随着具身智能（Embodied AI）研究的深入，赋予机器人理解非结构化环境并执行开放指令的能力成为核心议题。传统的几何地图缺乏语义信息，而早期的语义地图受限于封闭集标签，难以适应复杂的人机交互需求。近年来，结合神经辐射场（NeRF）、3D 高斯泼溅（3DGS）与视觉语言大模型（VLMs）的开放词汇场景图（Open-Vocabulary Scene Graphs）应运而生。本文首先梳理了从显式几何到神经隐式表征的技术脉络，对比分析了点云、体素、NeRF、3DGS 等不同表征方法的优劣。其次，针对现有 HOV-SG 等方法中存在的“计算重载”与“特征冗余”问题，结合复现实验与最新文献，深入探讨了图像预处理、特征融合策略对系统性能的影响。研究表明，通过基于信息熵的特征选择策略替代传统的特征平均，以及简化繁重的 SAM 分割管线，可以在保持甚至提升语义理解精度的同时，显著降低端侧计算开销。最后，本文结合空中抓取项目实践，探讨了 3D 场景图在无人机操作任务中的应用前景与技术挑战，展望了统一感知与生成的具身智能发展趋势。

关键词：3D 场景表征；开放词汇场景图；计算效率优化；空中机械臂；具身智能；3D 高斯泼溅

1 引言：从实际需求出发的思考

作为无人机空中具身智能项目的参与者，我的任务是让搭载机械臂的四旋翼在室内自主抓取指定物体。设计系统架构时却发现一个根本性矛盾：无人机视野狭窄、计算资源受限，但抓取任务却要求对整个房间有全局性的语义理解。

传统点云地图能告诉我“哪里有障碍物”，但无法回答“马克杯在哪里”；基于固定类别的检测器只能识别训练集中的物体，遇到近义词就会失效。更棘手的是，在无人机上部署 SAM+CLIP 组合时，单帧处理时间超过 1 秒，导致机载计算机（Jetson Orin）直接过载。

这些实际困境促使我深入研究 3D 场景图技术。开放词汇的 3D 场景图承诺用自然语言查询任意物体，并提供其三维位置与上下文关系——这正是我们项目所需。但复现 HOV-SG 算法^[2]的过程中，我逐渐认识到，学术界追求的“极致分割精度”与工程实践中的“实时性”之间存在巨大鸿沟。这也是本文的核心关切：如何在保留语义理解能力的前提下，让 3D 场景图真正走向实用？

1.1 计算机视觉的范式转移

计算机视觉的核心任务正从“被动感知”向“主动交互”转移。在 ImageNet 时代，系统只需在固定数据集上分类；而在具身智能时代，机器人需要在连续变化

的三维环境中实时理解“那是一把可以坐的椅子”或“那个红色物体是杯子，在桌子左边，旁边有一本书”。这种理解不仅包含几何信息（位置、形状），更需要语义信息（类别、功能）和拓扑关系（空间布局、物体交互）。

长期以来，机器人 SLAM 系统主要输出点云或体素网格，这些表征在避障导航方面表现优异，但在语义理解上存在严重的“语义鸿沟”^[1]。随着 Transformer 架构的普及以及 CLIP、SAM 等基础模型的爆发，将大模型知识“蒸馏”进 3D 空间，构建开放词汇场景图，已成为学术界的研究热点^[3]。

1.2 从堆砌到精简：效率的呼唤

现有解决方案（如 HOV-SG^[2]）往往陷入“堆砌模型”的误区。为追求分割效果，这些系统对每一帧运行 SAM，对每个物体反复调用 CLIP，并无差别地融合多视角特征。这种做法虽然在 Benchmark 上取得漂亮的数字，却带来难以承受的计算负载——在 RTX 4090 上复现 HOV-SG 时，处理 Replica 数据集的单个场景需要数分钟，这对于需要实时响应的机器人而言不可接受。

Kassab 等人在 2024 年底发表的《The Bare Necessities》^[4]通过系统消融实验揭示了一个反直觉的结论：许多被认为“必要”的模块其实可以大幅简化甚至移除，而不会显著损失性能（见图 4）。这篇论文促使我




图 1: 3D 场景表征技术的发展历程。左侧展示了从几何方法（点云、体素）到神经隐式方法（NeRF）再到显式神经方法（3DGS）的演进时间轴；右侧按机器人模块（感知、制图、定位、导航、操作）对这些表征方法进行了分类映射。^[1]

重新审视 HOV-SG 的每一个设计选择。

本文将通过文献综述与实践反思相结合的方式，探讨以下三个核心问题：

- **3D 场景表征技术经历了怎样的演进？** 各种表征方法（点云、体素、Mesh、NeRF、3DGS）的优劣对比如何？
- **现有开放词汇场景图的计算瓶颈在哪里？** 哪些模块是真正必要的，哪些可以被简化？
- **场景图技术如何服务于空中抓取等实际应用？** 当前存在哪些未解决的技术挑战？

2 3D 场景表征：技术脉络与性能对比

根据 Deng 等人^[1]最新论文，机器人领域的场景表征经历了从纯几何、到神经隐式、再到基础模型驱动的三个发展阶段（见图 1）。理解这一演进脉络，对于把握当前技术的优势与不足至关重要。

2.1 显式几何表征：高效但语义匮乏

早期 SLAM 系统主要输出点云或体素地图。点云作为激光雷达和 RGB-D 相机的原生输出格式，保留了完整的空间几何信息，但其离散、无序特性使得高层语义特征提取困难。体素网格通过规则网格划分空间解决了空间索引问题，经典的 TSDF 表征在稠密重建中广泛应用，但致命缺陷是内存消耗随分辨率立方级增长——要达到 1cm 分辨率，一个 $10m \times 10m \times 3m$ 的房间就需要 10^9 个体素。

用 Fast-LIO 构建点云地图对避障导航有效，但也有纯几何地图的局限：它们无法回答“这是什么”，更无法处理自然语言指令。

2.2 神经隐式表征：从 NeRF 到 3DGS 的革命

Wen 等人^[5]指出，神经辐射场（NeRF）的出现彻底改变了 3D 表征方式。NeRF 将场景编码为多层感知机（MLP）的权重，通过体渲染实现连续、高保真的

新视图合成:

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t) \sigma(\mathbf{r}(t)) \mathbf{c}(\mathbf{r}(t), \mathbf{d}) dt \quad (1)$$

其中 $T(t)$ 是透射率, σ 是体密度, $\mathbf{c}$ 是颜色。NeRF 实现了连续表示、隐式压缩和可微渲染, 可以任意分辨率查询, 将数 GB 的点云压缩为几 MB 的 MLP 权重, 并支持梯度优化融合语义特征。但 NeRF 的训练和推理速度极慢, 即使采用 Instant-NGP 等加速方案, 单场景训练仍需数分钟, 实时渲染难以达到 30 FPS, 对需要在线更新地图的移动机器人几乎不可用。

3D Gaussian Splatting (3DGS) 的出现标志着神经表征的又一次飞跃。3DGS 将场景表示为数百万个各向异性的高斯椭球, 每个椭球具有位置 μ 、协方差 Σ 、颜色 $\mathbf{c}$ 和不透明度 α 。通过可微的点云光栅化渲染, 3DGS 在 RTX 4090 上实现超过 100 FPS 的实时渲染 (1080p), 单场景优化仅需几分钟, 且每个高斯球可直接绑定语义特征, 无需复杂的查询网络。

Category	Data form	Continuous & Differentiable	Memory Efficiency	Photorealism	Flexibility	Geometric representation capability
Voxel		Discrete & Non-Differentiable	+++	+	++	++
Point Cloud		Discrete & Non-Differentiable	++	+++	+++	+++
Mesh		Discrete & Non-Differentiable	+++	++	+	++++
Scene Graph		Discrete & Non-Differentiable	++++	+	++++	+
Neural Radiance Fields (NeRF)		Continuous & Differentiable	+++	++++	+++	+++
3D Gaussian Splatting (3DGS)		Continuous & Differentiable	+	++++	+++	+++
Tokenizer		Continuous & Differentiable	++++	++++	+++	+++

图 2: 不同 3D 场景表征方法的定性对比。该矩阵展示了体素、点云、Mesh、场景图、NeRF、3DGS 等方法在数据形式、可微性、内存效率、光照真实感、灵活性和几何能力等维度的表现。^[1]

复现 HOV-SG 后, 尝试将其底层点云表征替换为 3DGS。虽然 HOV-SG 本身并非基于 3DGS 设计, 但 3DGS 的显式特性使其极易与语义特征绑定 (Feature Splatting)。每个高斯球除了存储 RGB 和 α 外, 还可以附加一个 512 维的 CLIP 特征向量。查询“红色杯子”时, 系统只需遍历高斯球并计算特征相似度, 而无需像 NeRF 那样逐点采样和 MLP 推理。

2.3 基础模型驱动的语义注入

为赋予 3D 表征开放词汇的语义理解能力, 研究者开始探索“特征场” (Feature Fields): 除了颜色和密

度, 还在 3D 空间中存储 CLIP 等大模型的高维语义向量。

CLIP 通过对比学习在 4 亿图文对上训练, 使得机器人可以响应任意自然语言查询, 而无需针对特定类别重新训练。SAM 提供通用物体分割能力, 其提示工程机制允许通过点、框或粗糙掩码来指导分割, 但计算成本极高——ViT-H 版本的单次前向传播在 4090 上需要约 200ms。特征场的构建流程通常为: 对 RGB-D 序列的每一帧用 SAM 提取物体掩码, 将掩码区域送入 CLIP 图像编码器获得 512 维特征向量, 根据相机位姿将 2D 特征反投影到 3D 空间并与现有特征融合。

但这里隐藏着两个关键问题: (1) 是否必须用 SAM? 简单的边界框裁剪能否胜任? (2) 多视角特征应该如何融合? 平均法是否合理? 这正是下一节要探讨的核心。

3 HOV-SG 的复现、分析与反思

作为开放词汇场景图的代表性工作, HOV-SG (Hierarchical Open-Vocabulary 3D Scene Graphs)^[2] 旨在构建包含物体、房间及其拓扑关系的层级化图结构。选择复现 HOV-SG 的主要原因: 一是其代码开源且文档完善, 二是其层级化设计与“全局定位+局部精细操作”需求高度契合。

3.1 HOV-SG 的核心算法流程

深入代码细节后, 总结出 HOV-SG 的主要处理流程 (见图 3): 系统对 RGB-D 序列逐帧调用 SAM 模型进行密集分割, 采用“全图自动分割”模式自动发现所有可能的物体, 输出每帧数十到上百个候选掩码。利用相机内参 K 和位姿 T , 将 2D 掩码反投影到 3D 点云空间:

$$\mathbf{p}_{3D} = T \cdot K^{-1} \begin{bmatrix} u \cdot d \\ v \cdot d \\ d \\ 1 \end{bmatrix} \quad (2)$$

关键问题是数据关联: 通过计算新观测点云与已有物体点云的 IoU 来判断, 若 IoU 超过阈值 (如 0.3), 则认为是同一物体, 将新点云合并; 否则新建物体实例。对每个 3D 物体实例, 系统维护其不同视角下的观测记录, 每次观测时将物体对应的 2D 区域裁剪并送入 CLIP 图像编码器, 提取 512 维特征向量 $\mathbf{f} \in R^{512}$ 存储在物体节点中供后续查询使用。最终构建三层图结构: 物体层的每个节点代表一个 3D 物体实例, 存储点




图3: HOV-SG 层级场景图构建流程。左侧为单帧处理: RGB-D 输入经 SAM 分割后投影到 3D 空间, 提取 CLIP 特征; 中间为增量式融合: 通过 IoU 进行数据关联, 合并多视角观测; 右侧为层级图构建: 基于几何聚类生成楼层-房间-物体三层结构, 并构建 Voronoi 导航图。^[2]

云、特征向量、边界框等信息; 房间层通过聚类算法将空间邻近的物体分组为房间; 关系边则通过几何约束判定物体间的空间关系。

3.2 复现中的性能瓶颈与问题分析

在基于 Replica 数据集的复现实验中 (硬件环境: NVIDIA RTX 4090, 24GB 显存), 观察到显著的性能问题, 这验证了 Kassab 等人^[4]《The Bare Necessities》中的观点:

问题 1: 极高的计算延迟

系统处理单帧的平均耗时超过 1 秒, 导致整体运行帧率远低于 1 FPS。经性能剖析, 瓶颈主要在于 SAM 推理 (每帧约耗时 400-600ms)、CLIP 编码 (若一帧中有 20 个物体, 即使批处理也需 100-200ms) 以及点云处理 (反投影、IoU 计算、点云合并等操作虽然可用 GPU 加速, 但频繁的 CPU-GPU 数据传输也是隐性开销)。处理 Replica 数据集中包含 2000 帧的序列需要 30-40 分钟。这对于需要在线建图的移动机器人而言不可接受。

问题 2: 显存占用随时间线性增长

HOV-SG 需要维护所有物体的历史点云和特征向量。在长序列中, 随着新物体不断被发现, 显存占用持续攀升。处理 Replica 的“office_0”场景时, 显存占用从初始的 2GB 增长到超过 18GB。虽然可以通过定期清理未观测到的物体来缓解, 但这又引入“遗忘”旧物体的风险。

问题 3: 特征噪声与质量退化 HOV-SG 采用**特征平均策略**融合多视角观测:

$$\mathbf{f}_{obj} = \frac{1}{N} \sum_{i=1}^N \mathbf{f}_i \quad (3)$$

其中 $\mathbf{f}_i$ 是第 i 次观测的 CLIP 特征。这一策略假设多视角平均可以降低噪声, 提升鲁棒性。




图5: 展示了同一台灯在 5 个不同视角下的识别结果, 这种不一致性说明简单的特征平均策略会引入大量噪声。^[4]

然而, 实际复现中发现, **CLIP 对视角极其敏感** (见图 5)。同一个杯子, 从正面拍摄时被准确识别为“cup”, 但从俯视角度拍摄时可能被识别为“bowl”甚至“plate”。更糟糕的是, 当物体被部分遮挡时, CLIP 常输出完全错误的类别 (如将白墙识别为“whiteboard”)。

将高质量特征与低质量特征简单平均, 本质上是在降低信噪比。这就像统计考试成绩时将学霸和学渣的分数平均——最终得到的是平庸的结果, 而非对学生真实水平的准确反映。

3.3 对“必要性”的质疑: 来自实验的反思

反复调试 HOV-SG 过程中, 开始怀疑: **SAM 和特征平均真的是必需的吗?** 这种怀疑在读到 Kassab 等人的论文后得到印证。他们通过消融实验揭示了几个反直觉的结论:

发现 1: SAM 的性价比极低

实验对比了三种预处理方式: 直接用检测器的边界框裁剪、用 SAM 精细分割后再裁剪、将边界框扩大 1.5 倍后裁剪。在 ScanNet++ 数据集上, 三种方法的 Zero-shot 分类准确率分别为: 62.3%、63.1%、**64.8%**。**最简单的扩充裁剪法反而最优^[4]**, 而 SAM 仅带来 0.8% 的微弱提升, 却将单视角处理时间从 78ms 暴增到 314ms——**计算成本增加 3 倍, 精度提升不到 2%** (见图 4)。

这一结果的原因可能在于: CLIP 在预训练时见过的大多数图像都包含背景, 因此适当保留上下文 (如




图 4: 《The Bare Necessities》论文的核心贡献。展示了 ConceptGraphs (0.16 FPS)、HOV-SG (0.03 FPS) 与简化方法 (0.51 FPS) 的速度对比及分割效果。可以看出, 简单方法在效率上有数倍至数十倍提升, 且精度未损失。^[4]

物体周围的桌面、墙壁) 反而有助于模型理解。过度精细的掩码可能“切断”了这种上下文信息。

发现 2: 特征平均不如特征选择

论文进一步研究了多视角特征融合策略: 取所有视角特征的均值、对每个维度取最大值、选择置信度最高的单个视角。基于熵的选择方法计算每个视角的预测熵:

$$H(\mathbf{f}) = - \sum_{i=1}^C p_i \log p_i \quad (4)$$

其中 $p_i = \exp(\mathbf{f} \cdot \mathbf{t}_i) / \sum_j \exp(\mathbf{f} \cdot \mathbf{t}_j)$ 是对第 i 个候选类别的 softmax 概率。**熵越低, 说明模型越确信。**因此, 应选择熵最低的那个视角作为物体的代表特征。

实验结果显示, 熵选择法的准确率比平均法高出 **4.2 个百分点**, 且无需额外计算 (甚至更快, 因为避免了多次特征累加)。这印证了直觉: **少即是多, 质量胜于数量。**

4 空中抓取中的场景图应用

本节回归实际项目需求, 探讨场景图技术在空中机械臂操作中的应用前景。

空中机械臂在多旋翼无人机上搭载机械臂, 实现高空或难以到达区域的物体抓取与操作任务。相比地面机器人, 空中操作需要应对全局-局部的二元需求 (既要房间尺度的全局定位, 又要厘米级的精细操作)、极度受限的计算资源 (使用 Jetson Orin Nano, 8GB 内存, 15W 功耗) 以及动态环境中的实时对齐。

如图 6 所示, 完整的语言引导空中抓取系统包含三大模块: (1) **语言任务规划**: 基于 3D 场景图和大语言模型, 将自然语言指令分解为可执行的子任务序列, 并查询目标物体的语义位置; (2) **机载建图与定**

位: 通过 LIO 进行全局定位, 使用 FoundationPose 等方法实时感知物体姿态, 并在场景图中进行语义与几何对齐; (3) **空中机械臂规划**: 基于场景图提供的粗略位置进行路径搜索, 生成抓取姿态, 优化时空轨迹, 最终通过状态估计与控制器实现精确抓取。

场景图的层级结构恰好匹配这一需求。然而, 当前仍存在诸多未解决的挑战。**首先是抓取点的生成与可达性分析**: 场景图通常只提供物体的整体点云和语义标签, 但不直接给出“从哪里抓”的信息, 且必须考虑螺旋桨下洗气流、机械臂工作空间受限以及无人机悬停位姿与机械臂末端的耦合约束。**其次是分割粒度与任务需求的不匹配**: HOV-SG 倾向于欠分割 (例如将桌上的书本、杯子、键盘全部合并为“桌面杂物”), 对导航任务可以接受, 但对抓取任务是致命的。理想情况下, 系统应支持可变粒度的分割, 一个可能的方案是采用层级掩码树。**第三是动态物体的持续跟踪**: 现有方法假设环境是静态或准静态的, 但实际部署中人可能会在无人机面前拿走或放置物体。一个初步思路是引入时间维度, 将场景图扩展为时空图。




图 7: IRS 系统与 HOV-SG 的对比。上行为 HOV-SG 的重建结果, 存在语义冲突 (红色圈出); 下行为 IRS 基于房间先验的重建结果, 处理速度更快, 语义一致性更好。^[6]

调研中发现 IRS^[6] (2024) 提出了基于 LiDAR-Camera 融合的实例级场景图, 强调房间先验的利用, 将处理速




图 6: 语言引导的空中机械臂作业端到端流程。该图展示了一套全集成系统, 可让空中机械臂根据自然语言指令自主执行任务, 涵盖 3D 场景理解、基于大语言模型的任务规划、机载定位、轨迹优化及实时状态估计与控制等环节。

度相比 HOV-SG 提升约 44 倍 (见图 7)。这对工作很有启发——可以在场景图构建时引入建筑结构先验, 避免将跨房间的物体错误关联。

5 从感知到生成: 具身智能的未来展望

当前的 3D 场景表征研究正站在一个新的转折点上。过去十年, 学术界主要聚焦于“如何更准确地感知环境”; 而未来的趋势可能是“如何让感知与生成、理解与交互相互促进”。

5.1 生成式模型的双重角色

Wen 等人^[5]揭示了一个有趣的现象: 生成式模型不仅用于创造虚拟数据, 更可以作为机器人的“世界模型”。传统的感知流程是: 观测环境 → 构建地图 → 规划行动。但如果机器人拥有一个生成式世界模型, 流程可以变为: 观测环境 → 更新世界模型 → 预测未来状态 → 规划行动。这种预测能力在空中抓取中尤为重要——例如, 当无人机接近物体时, 可以预测“如果我从这个角度抓取, 物体会如何运动”, 从而提前调整策略。

扩散模型和 NeRF 的结合已经展现出强大的场景编辑能力。未来, 机器人或许可以用类似技术进行“心理演练”: 在虚拟场景中模拟各种抓取策略, 选择成功率最高的方案后再执行。

5.2 统一的感知-生成框架

当前, 感知和生成是两个相对独立的研究领域。但从信息论角度看, 二者本质上都是在学习数据的分布 $p(\mathbf{x})$ ——感知是推断 $p(\mathbf{x}|\text{观测})$, 生成是采样 $p(\mathbf{x}|\text{条件})$ 。

是否可以用统一的架构同时支撑感知与生成? 一些最新工作已经迈出了第一步。对于具身智能而言, 理想的系统应该是: 既能从观测中构建场景图 (感知), 也能根据场景图生成新的视角或预测未来状态 (生成)。这种双向能力将极大提升机器人的环境理解与任务规划能力。

5.3 轻量化与端侧部署的必要性

无论技术多么先进, 如果无法在资源受限的设备上运行, 对实际应用而言都是空中楼阁。复现 HOV-SG 时的最大感触是: 学术界追求的 Benchmark 数字与工业界需要的实时性之间存在巨大鸿沟。

未来的研究应更加重视模型蒸馏、稀疏计算、增量更新以及云边协同等方向。正如 Kassab 等人^[4]所倡导的“极简主义”哲学: 真正好的系统不是堆砌最多的模型, 而是用最少的计算实现最优的效果。

6 结论: 技术与应用的双向驱动

本文从实际项目需求出发, 系统综述了 3D 场景表征技术的演进脉络, 深入分析了开放词汇场景图的构建方法与优化策略, 并探讨了该技术在空中抓取等实际应用中的前景与挑战。

通过对 HOV-SG 的复现与反思, 认识到: 当前学术界对于“堆砌模型”的路径依赖亟需反思。SAM、CLIP 等基础模型固然强大, 但简单地将它们组合并不能自动带来最优性能。正如 Kassab 等人所揭示的, 许多被认为“必要”的模块其实可以大幅简化——基于信息熵的特征选择比特特征平均更有效, 扩充裁剪比 SAM 掩码性价比更高。这些看似“反直觉”的结论, 实则蕴含着

深刻的工程智慧：**效率与精度的平衡点往往不在技术的极致，而在需求的必要。**

从几何重建走向语义理解，再到高效、实时的开放交互，是3D场景表征发展的必由之路。而推动这一进程的，不应仅是Benchmark上的数字提升，更应是来自实际应用的真实需求。**技术与应用的双向驱动，才能让3D场景图真正走出实验室，走向广阔的现实世界。**

展望未来，我认为以下几个方向值得深入探索：

- **3DGS作为统一表征**：其显式特性与实时性使其有望取代NeRF成为下一代机器人标准地图格式
- **感知与生成的统一框架**：让机器人既能理解环境，

也能预测未来，支撑更智能的决策

- **可变粒度的分割与查询**：根据任务需求动态调整场景图的语义精细度
- **端侧轻量化**：通过模型压缩、稀疏计算等技术，让大模型真正在移动机器人上运行

作为一名刚刚踏入这一领域的学生，我深知自己的理解还很浅薄。但正是在复现算法、调试代码、解决实际问题的过程中，我才真正体会到了——**梁老师课上提的研究要为了解决真实的问题而探索未知。**希望本文的思考能为后续研究者提供一些参考，也期待3D场景表征技术能在不久的将来真正赋能具身智能的发展。

参考文献：

- [1] DENG T, WU G, CHEN H, et al. What is the best 3D scene representation for robotics? from geometric to foundation models[J]. IEEE Transactions on Robotics (Early Access), 2026.
- [2] WERBY A, HUANG C, BÜCHNER M, et al. Hierarchical open-vocabulary 3D scene graphs for language-grounded robot navigation [C]//Robotics: Science and Systems (RSS). 2024.
- [3] KOCH S, VASKEVICIUS N, COLOSI M, et al. Open3DSG: open-vocabulary 3D scene graphs from point clouds with queryable objects and open-set relationships[C]//IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 9224-9232.
- [4] KASSAB C, MATTAMALA M, MORIN S, et al. The bare necessities: designing simple, effective open-vocabulary scene graphs[A]. 2024.
- [5] WEN B, XIE H, CHEN Z, et al. 3D scene generation: a survey[A]. 2025.
- [6] GU J, WANG Z, WANG R, et al. IRS: instance-level 3D scene graphs via room prior guided LiDAR-camera fusion[A]. 2024.
- [7] LV C, WANG M, XU X, et al. SGFormer: semantic graph transformer for point cloud-based 3D scene graph generation[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 38. 2024: 3674-3682.
- [8] HUGHES N, CHANG Y, CARLONE L. Hydra: a real-time spatial perception system for 3D scene graph construction and optimization [C]//Robotics: Science and Systems (RSS). 2022.